LABORATOIRE HUBERT CURIEN
UMR • CNRS • 5516 • SAINT-ETIENNE

UNIVERSITÉ DE LYON

Analyse et traitement des données

Master 1 Informatique
Parcours
« Données et Systèmes Connectés » (DSC)
Saint-Étienne, France

Fabrice MUHLENBACH
https://perso.univ-st-etienne.fr/muhlfabr/
e-mail : fabrice.muhlenbach@univ-st-etienne.fr

Organisation de l'enseignement

1. Cours magistraux : 10 heures

2. Travaux dirigés : 10 heures
   (nécessité d'une calculatrice scientifique,
   d'un dé à 6 faces, d'une pièce de monnaie,
   de papier à petits carreaux, d'un crayon,
   d'une règle et d'une gomme)

3. Travaux pratiques avec  : 10 heures
   (ordinateur portable personnel conseillé)

Évaluation de l'enseignement

1. Partie théorique : 70%

2. Partie pratique
   (exercices sur machine avec ) : 30%

Objectifs de l'enseignement

Analyse et traitement des données :

- processus d'inspection, de transformation, de visualisation et de modélisation des données

- dans le but de découvrir des informations utiles, de suggérer des conclusions et d'appuyer des prises de décision

Plan

1. Rappels de probabilités et statistiques
2. Algèbre linéaire
3. Régression linéaire
4. Analyse en composantes principales
5. Méthodes de classification

Analyse et traitement des données

- Utilisation de 

Pourquoi  **?**

- évolution :
  logiciel de statistique → outil d'analyse utilisable par tous
- succès lié à une forte communauté de développeurs
- aller au-delà des limites des tableurs pour l'analyse de données (nombre de lignes et colonnes, fonctionnalités…)
- permet l'analyse de données sans avoir besoin de programmer des dizaines de lignes de code d'un langage informatique classique (gain de temps)
- outil important pour les sciences expérimentales :
  expériences → données → analyse

• Qu'est-ce que R ?

- logiciel d'analyse de données (langage + interpréteur)
- historique : langage ***S*** (laboratoires Bell) en 1976
- évolution : ***S-plus*** (1988), logiciel pour spécialistes
- création de ***R***, clone open-source de ***S*** en 1996
  R-Core Team (Université d'Auckland), petite communauté
- ***R*** est modulaire : base + packages (plus de 19 000) distribués sur le site ***R*** officiel appelé CRAN
  (*Comprehensive R Archive Network*),
  voir : https://cran.r-project.org/web/packages/
- ***R*** implémente une version du langage ***S*** dans un environnement piloté en ligne de commande (console)
- mais utilisation aussi possible dans un environnement de développement applicatif agréable : ***RStudio / Posit***

• Qu'est-ce que R ? (suite)

- langage interprété (mais compilation possible)
- langage fonctionnel : appel de fonctions avec passage d'arguments par valeurs
- langage non typé (conversion de variable automatiquement si nécessaire)
- taille des vecteurs et des tableaux redimensionnables
- permet un usage interactif
- tout est objet dans ***R,*** ces objets sont vectorisés et toute opération faite sur ces objets doit fonctionner de façon vectorisée

```
> 3 + 1
[1] 4

> 1:3 + 1
[1] 2 3 4
```

• Qu'est-ce que R ? (suite)

- pourquoi travailler sur des vecteurs ?
  des données expérimentales arrivent en nombre,
  il est donc normal de les traiter en tant que vecteurs
- moins de programmation avec ***R*** car on réutilise des fonctions déjà programmées (packages)
- ***R*** fonctionne aussi bien sous les systèmes d'exploitation de Windows que macOS ou Linux
- ***R*** est gratuit et distribué en licence GPL (*GNU General Public License*)
- ***R*** s'installe facilement par un fichier exécutable d'installation depuis le site du CRAN ou de sites miroirs locaux : https://cran.r-project.org/mirrors.html

• Avantages de R par rapport aux tableurs

Limites du tableur :

- dans un tableur, le nombre de lignes est limité
- mélange de données et de calculs : compréhension difficile
- le recalcul d'une feuille n'est pas linéaire
- calcul et stockage des données pas optimaux
- données non structurées
- du point de vue des statistiques, les graphiques et les fonctions de calcul présents dans un tableur sont faibles (en choix, en options, en compréhension…)
- nécessité de passer par des macro-commandes : série de commandes exécutées l'une après l'autre, toujours dans le même ordre, afin d'automatiser certaines tâches répétitives

Travailler avec des variables

- affectation d'une valeur à une variable :

```
x <- 1
x = 1
```

- variable numérique : `x = 10.5`
- affichage de la catégorie de la variable :

```
class(x)
[1] "numeric"
```

- les variables peuvent être logiques (`TRUE` / `FALSE`), complexes (`1 + 2i`), des chaînes de caractères, des vecteurs, des matrices, des listes, des *data frames* ou des objets très divers (graphes, images, connexions à une base de données…)

Travailler avec des variables

- opérateurs arithmétiques :
  addition : `+`
  soustraction : `-`
  multiplication : `*`
  division : `/`
  exponentiation : `^` ou `**`
  modulo : `%%`
  division entière : `%/%`

- opérateurs logiques :
  inférieur : `<`
  supérieur : `>`
  inférieur ou égal : `<=`
  supérieur ou égal : `>=`

égalité : `==`
différent : `!=`
non : `!`
et : `&`
ou : `|`

Automatisation des traitements

- tests :

```
if (condition){
    instructions si vrai
    } else {
    instructions si faux
    }
```

- exemple :

```
x <- 1
if (x == 1){
  "x est égal à 1"
  } else {
  "x est différent de 1"
  }
```

Automatisation des traitements

- boucles avec un nombre de répétitions connu :
  `for (`variable `in` liste`)` instruction
- exemple 1 :

```
for (i in seq(from=5, to=15, by=5)) print(i)
[1] 5
[1] 10
[1] 15
```

- exemple 2 :

```
for (i in 1:3) print(i * 4)
[1] 4
[1] 8
[1] 12
```

Automatisation des traitements

- boucles avec un nombre de répétitions inconnu :
  `while (condition) instruction`
- exemple :

```
i <- 0
while (i <= 25) {
  print(i)
  i <- i + 10
  }
```

- résultat :

```
[1] 0
[1] 10
[1] 20
```

Automatisation des traitements

- utilisation de fonctions :
  `function(`liste d'arguments`)` expression
  `return(`valeur`)`
- exemple de création de fonction :

```
maFonction <- function(a,b,c,x){
  y <- a * x^2 + b * x + c
  return(y)
}
```

- utilisation de la fonction créée :

```
> maFonction(1, 2, 3, 4)
[1] 27
> maFonction(4, 3, 2, 1)
[1] 9
```

Stockage des données dans un data frame

- structure de données spécifique
- format : *x* lignes × *y* colonnes
  correspondant à : *x* individus × *y* variables
- liste de vecteurs de mêmes longueurs mais de formats (éventuellement) différents : entier, réel, logique, facteur…
- format le plus utilisé pour le traitement des données
- les variables ont des noms, ce qui permet d'accéder à des données spécifiques en indiquant un indice spécifique
- utilisation :
  - indice numérique pour indiquer une ligne ou une colonne
  - nom de la variable précédé du symbole $

Stockage des données dans un data frame

- création du data frame

```
v1 <- c(14, 8.5, 13.8, 15)
v2 <- (v1 >= 10)
v3 <- factor(c("M", "F", "M", "F"))

# liste
liste <- list(v1,v2,v3)

# data.frame
donnees <- data.frame(liste)

# nommer les colonnes et les lignes
colnames(donnees) <- c("Note","Reussite","Genre")
rownames(donnees) <- c("Pierre","Pauline","Jacques","Mathilde")
```

Stockage des données dans un data frame

- affichage des données

```
> print(class(donnees))
[1] "data.frame"
> print(summary(donnees))
      Note         Reussite        Genre
 Min.   : 8.50   Mode :logical   F:2
 1st Qu.:12.47   FALSE:1         M:2
 Median :13.90   TRUE :3
 Mean   :12.82   NA's :0
 3rd Qu.:14.25
 Max.   :15.00
> print(donnees)
         Note Reussite Genre
Pierre   14.0     TRUE     M
Pauline   8.5    FALSE     F
Jacques  13.8     TRUE     M
Mathilde 15.0     TRUE     F
> donnees$Genre[2]
[1] F
Levels: F M
```

Stockage des données dans un data frame

- sélection des données

```
> # Sélection d'un individu (ligne) par indice
> donnees[1,]
       Note Reussite Genre
Pierre   14     TRUE     M
> # Sélection d'une variable (colonne) par indice
> donnees[,1]
[1] 14.0  8.5 13.8 15.0
> # Sélection d'une variable par nom de variable
> donnees$Note
[1] 14.0  8.5 13.8 15.0
```

Stockage des données dans un data frame

- sélection des données avec conditions

```
> # Affichage des individus dont le genre est masculin
> donnees[donnees$Genre == "M",]
        Note Reussite Genre
Pierre  14.0     TRUE     M
Jacques 13.8     TRUE     M
> # Affichage des individus ayant réussi l'examen
> donnees[donnees$Reussite == "TRUE",]
         Note Reussite Genre
Pierre   14.0     TRUE     M
Jacques  13.8     TRUE     M
Mathilde 15.0     TRUE     F
> # ou, plus simplement :
> donnees[donnees$Reussite,]
         Note Reussite Genre
Pierre   14.0     TRUE     M
Jacques  13.8     TRUE     M
Mathilde 15.0     TRUE     F
```

Manipulation des données

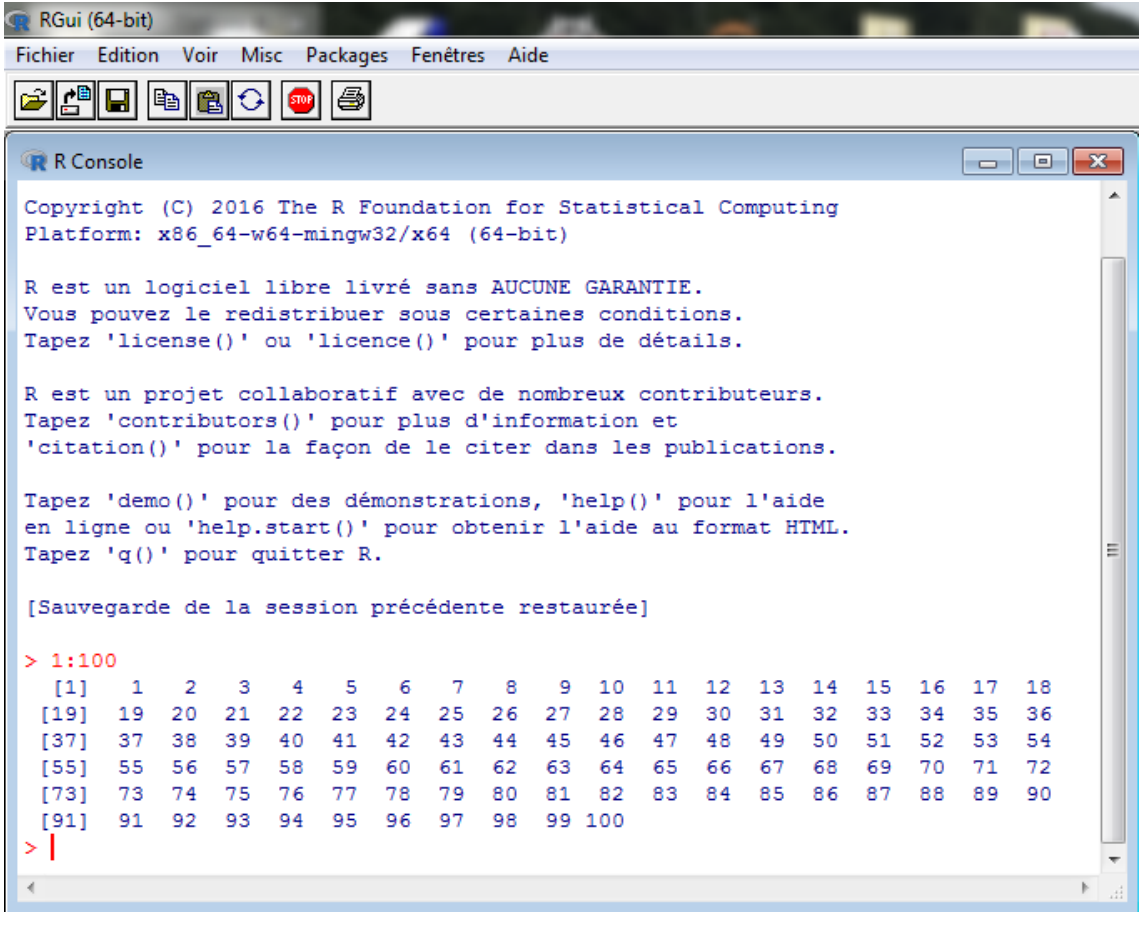
- lecture et écriture des données dans des fichiers

```
read.table()
write.table()
read.csv()
write.csv()
read.xlsx()
write.xlsx()
nrow()
ncol()
```

- exemple : `df <- read.csv("~/R/data/df.csv")`

• Environnement de travail avec R

Mode console

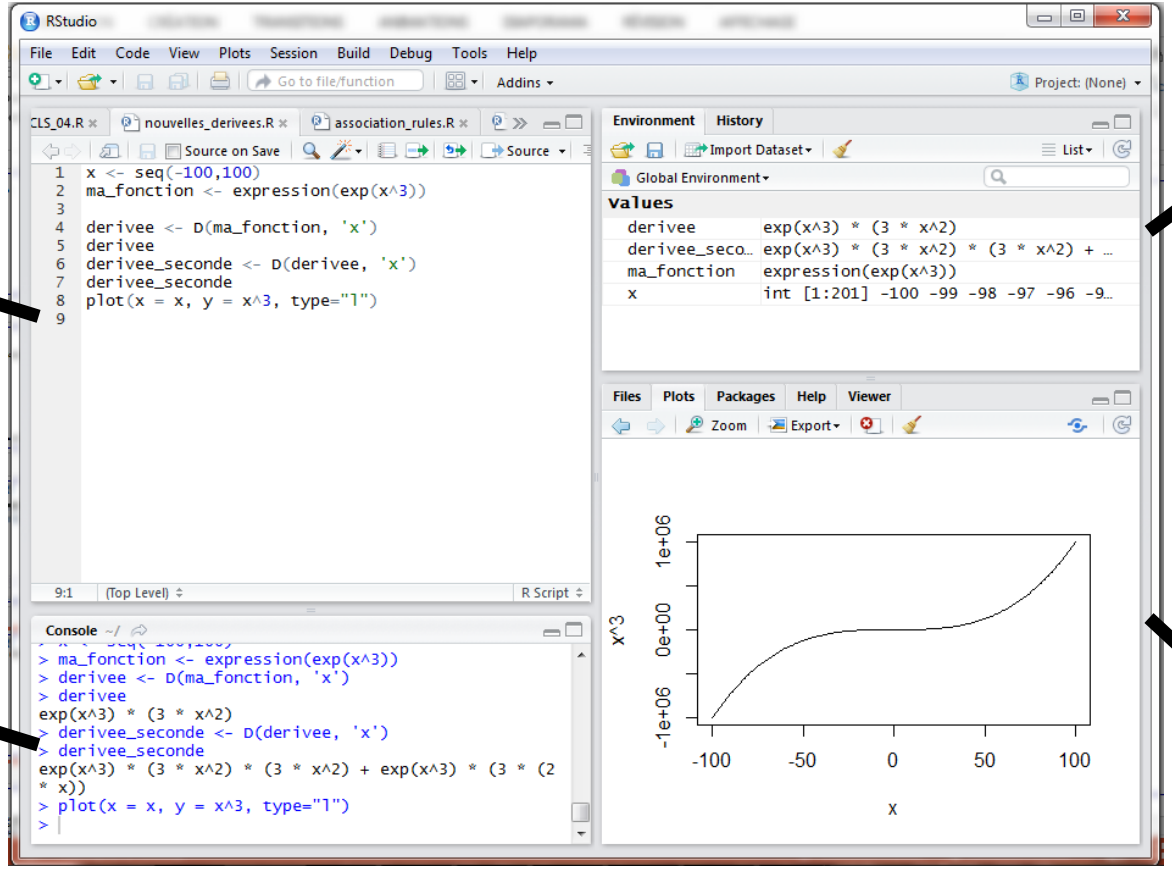


• Environnement de travail avec R

Environnement de développement intégré (RStudio / Posit)

éditeur de scripts

console



fichiers
variables
fonctions

graphiques
packages
aide

• Conclusion sur R

Analyse et traitement des données avec R

- identification du problème dans tout domaine des sciences expérimentales producteur de données à traiter et analyser, mais aussi en sciences humaines et sociales (ex. textes)
- recherche d'un package approprié sur le site CRAN ou un site particulier trouvé par un moteur de recherche
- lecture du fichier d'aide et / ou de la vignette
- installation du package (et des dépendances éventuelles)
- test des fonctions du package sur un exemple jouet
- application aux données qui nous intéressent
- adaptation éventuelle par des lignes de code pour des traitements spécifiques (programmation)

Introduction

- Les différentes étapes de l'analyse de données

L'analyse de données s'effectue classiquement suivant un processus en 3 étapes :

1. comprendre la nature du problème étudié
   (décider quoi mesurer à partir d'un ensemble de données)

2. résumer l'information et effectuer les analyses préliminaires

3. mener une analyse formelle complète

Introduction

- Les différentes étapes de l'analyse de données

Exemple :

MLS (integer)	Location (character)	Price (double)	Bedrooms (integer)	Bathrooms (integer)	Size (integer)	Price/SQ.Ft (double)	Status (character)
132842	Arroyo Grande	795000	3	3	2371	335.30	Short Sale
134364	Paso Robles	399000	4	3	2818	141.59	Short Sale
135141	Paso Robles	545000	4	3	3032	179.75	Short Sale
135712	Morro Bay	909000	4	4	3540	256.78	Short Sale
136282	Santa Maria-Orcutt	109900	3	1	1249	87.99	Short Sale
136431	Oceano	324900	3	3	1800	180.50	Short Sale
137036	Santa Maria-Orcutt	192900	4	2	1603	120.34	Short Sale
137090	Santa Maria-Orcutt	215000	3	2	1450	148.28	Short Sale

House dataset
Source: https://wiki.csc.calpoly.edu/datasets/wiki/Houses

Introduction

• Les différentes étapes de l'analyse de données

- Ce jeu de données contient une collection d'informations immobilières dans le comté de San Luis Obispo (Californie)
- Variables présentes :

➢ MLS : *Multiple listing service number* (identifiant unique)
➢ Location : ville où se trouve la maison
➢ Price : prix le plus récent de maison (en dollars US)
➢ Bedrooms : nombre de chambres
➢ Bathrooms : nombre de salles de bain
➢ Size : surface de la maison (en *square feet*)
➢ Price/SQ.ft : rapport du prix de la maison par sa surface
➢ Status : type de vente : *Short Sale* (vente à découvert), *Foreclosure* (forclusion) et *Regular* (location classique)

Introduction

- Les différentes étapes de l'analyse de données

- **comprendre la nature du problème étudié**
  (décider quoi mesurer à partir d'un ensemble de données)

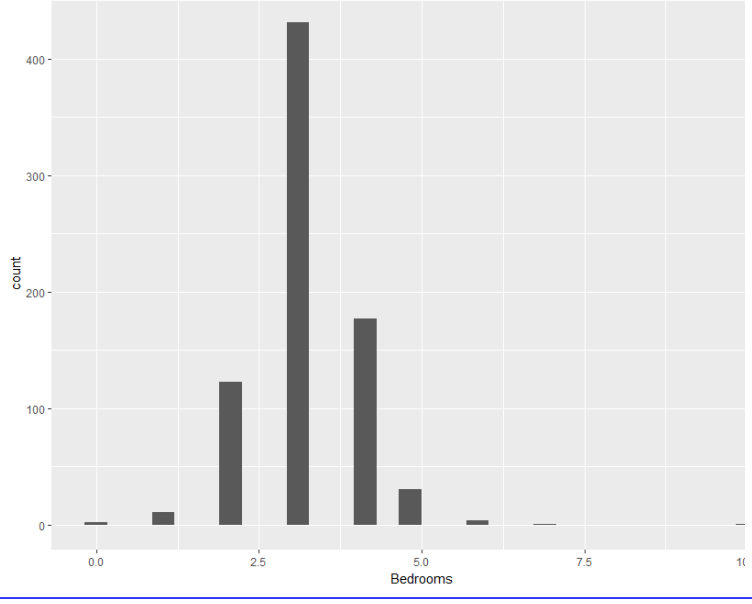
- la superficie de la maison, le nombre de chambres et de salles de bain ou le statut de la maison sont autant de variables permettant de comprendre le prix d'une maison

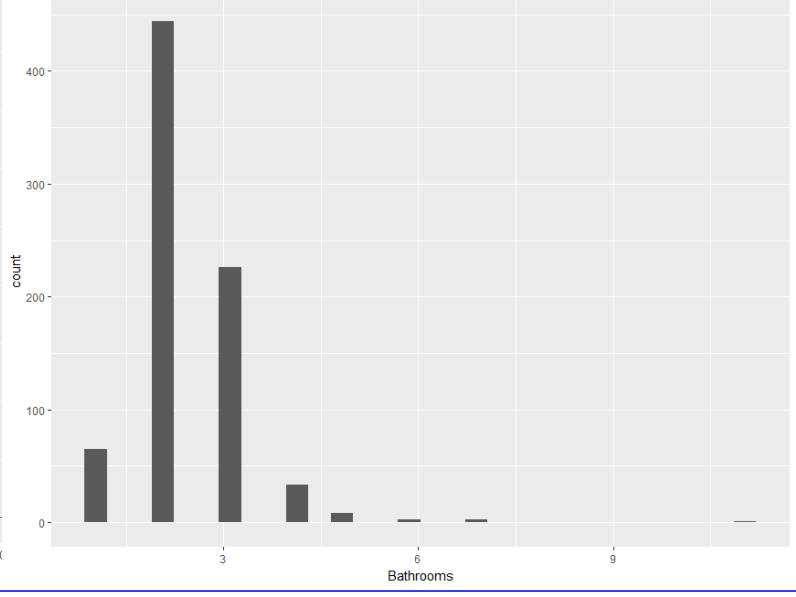
- il s'agit de variables pertinentes pour l'étude du prix de la maison

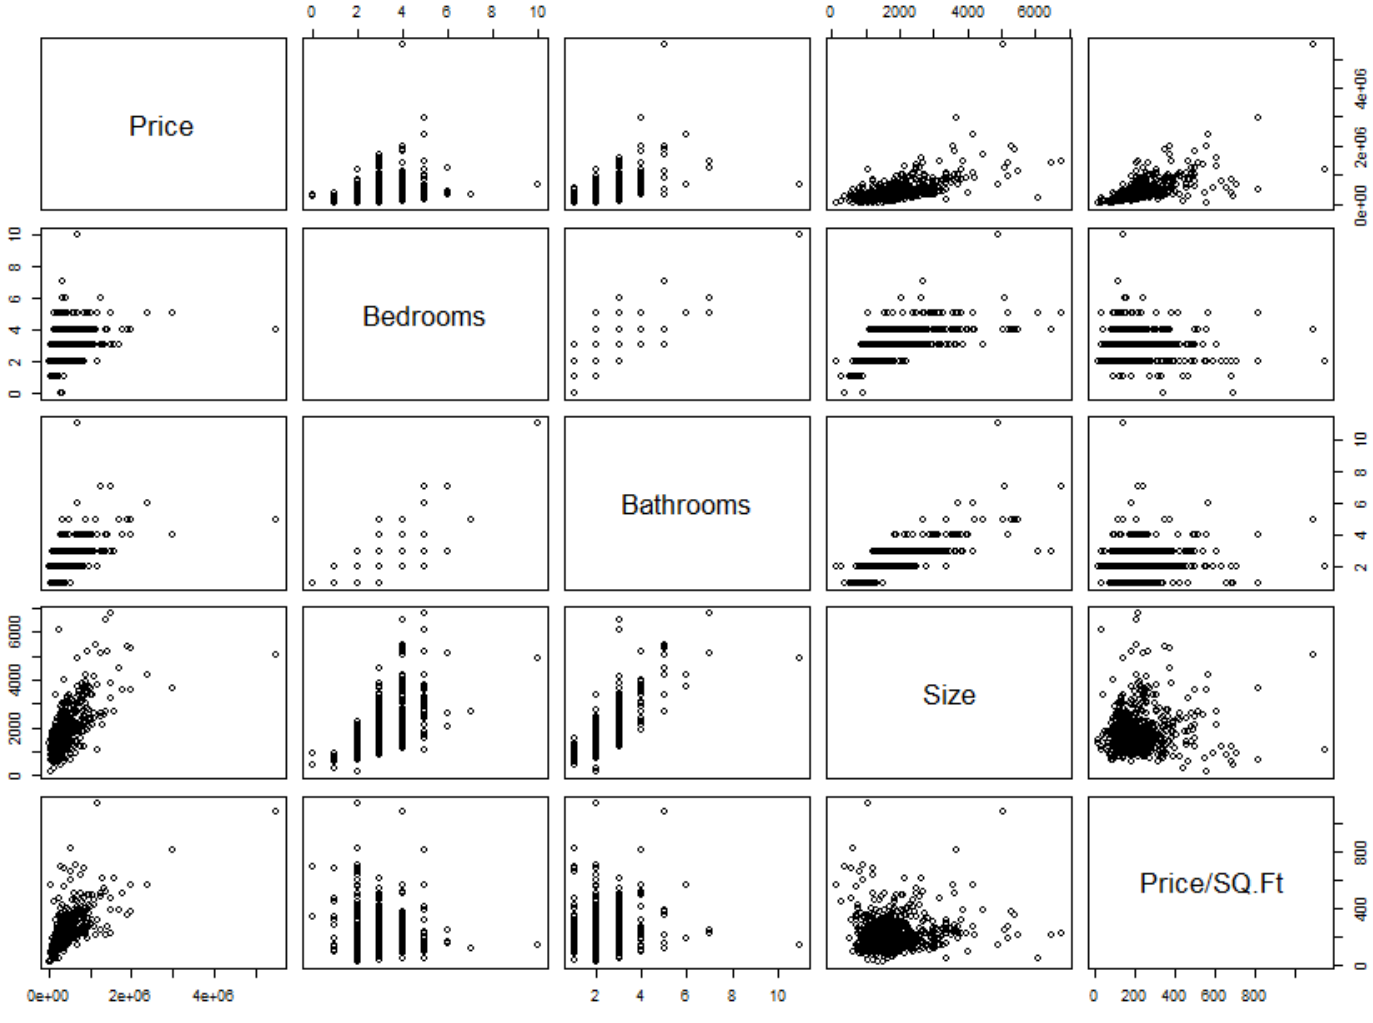
Introduction

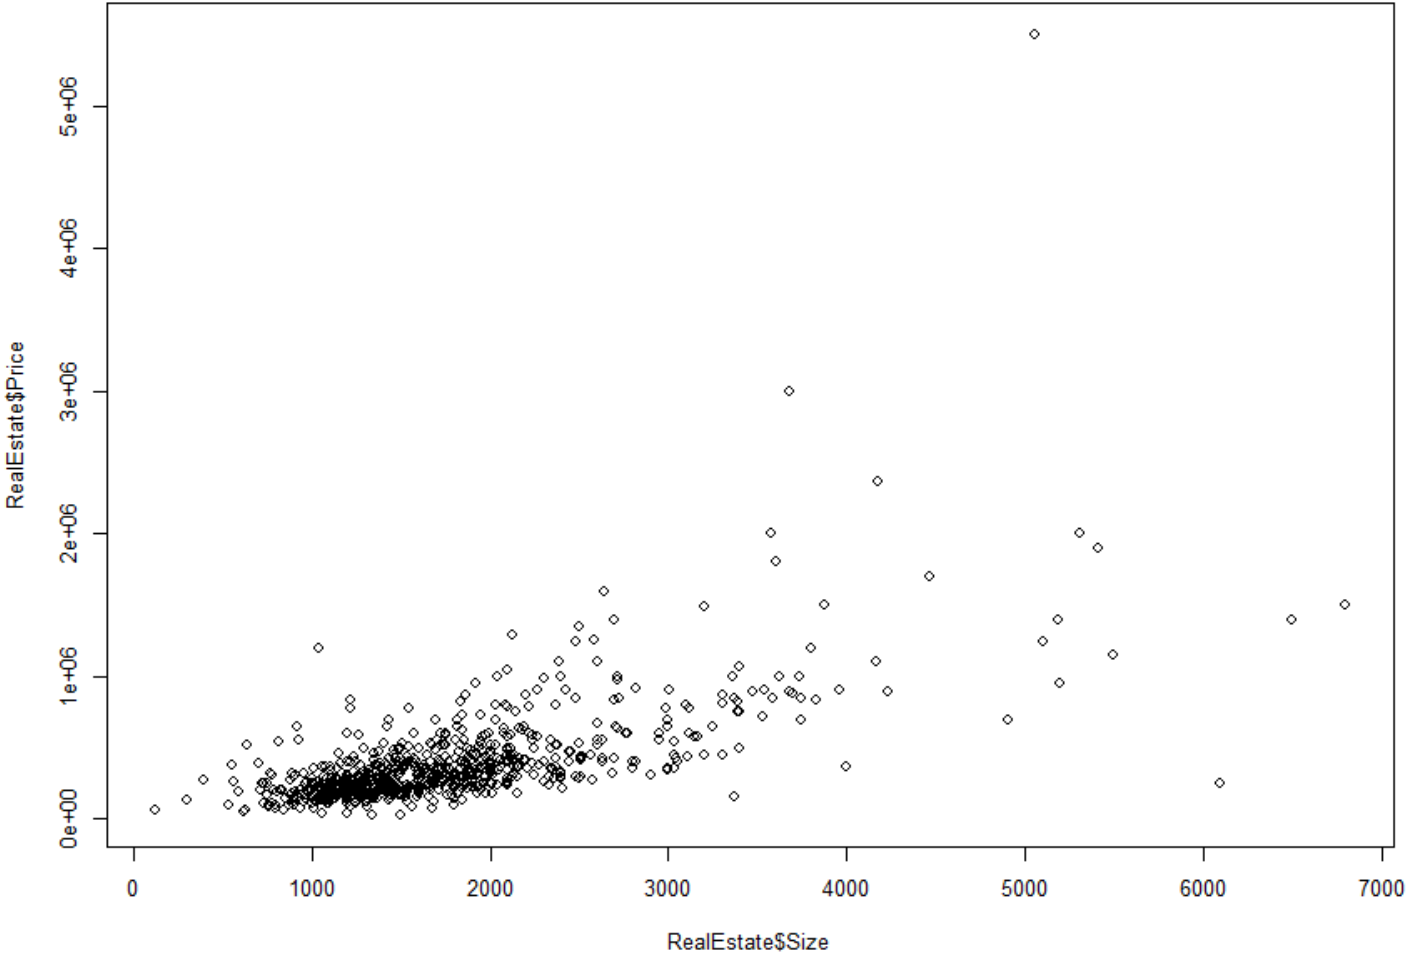
- Les différentes étapes de l'analyse de données

- **résumer l'information et effectuer les analyses préliminaires**
- on peut résumer l'information sous forme graphique






Price
Bedrooms
Bathrooms
Size
Price/SQ.Ft


RealEstate$Price
0e+00
1e+06
2e+06
3e+06
4e+06
5e+06
0
1000
2000
3000
4000
5000
6000
7000
RealEstate$Size

Introduction

- Les différentes étapes de l'analyse de données

- **résumer l'information et effectuer les analyses préliminaires**
- on peut résumer l'information sous forme numérique

```
      MLS             Location           Price             Bedrooms         Bathrooms         Size
 Min.   :132842   Length:781         Min.   :  26500   Min.   : 0.000   Min.   : 1.000   Min.   : 120
 1st Qu.:149922   Class :character   1st Qu.: 199000   1st Qu.: 3.000   1st Qu.: 2.000   1st Qu.:1218
 Median :152581   Mode  :character   Median : 295000   Median : 3.000   Median : 2.000   Median :1550
 Mean   :151225                      Mean   : 383329   Mean   : 3.142   Mean   : 2.356   Mean   :1755
 3rd Qu.:154167                      3rd Qu.: 429000   3rd Qu.: 4.000   3rd Qu.: 3.000   3rd Qu.:2032
 Max.   :154580                      Max.   :5499000   Max.   :10.000   Max.   :11.000   Max.   :6800

   Price/SQ.Ft        Status
 Min.   :  19.33   Length:781
 1st Qu.: 142.14   Class :character
 Median : 188.36   Mode  :character
 Mean   : 213.13
 3rd Qu.: 245.42
 Max.   :1144.64
```

Introduction

• Les différentes étapes de l'analyse de données

- **résumer l'information et effectuer les analyses préliminaires**
- on peut résumer l'information sous forme numérique
- quel est le prix moyen d'une maison ?
- quel est l'écart-type ?
  → informations issues de la statistique descriptive

- quelle est la corrélation entre le prix de la maison et le nombre de chambres de la maison ?

- besoin de traitements plus sophistiqués
  → analyse de données formelle

Introduction

• Les différentes étapes de l'analyse de données

- **mener une analyse formelle complète**

- comment construire une estimation non biaisée d'un paramètre donné (p. ex, le vrai prix d'une maison) en utilisant un ensemble fini de données observées ?
  → p. ex. utilisation du maximum de vraisemblance

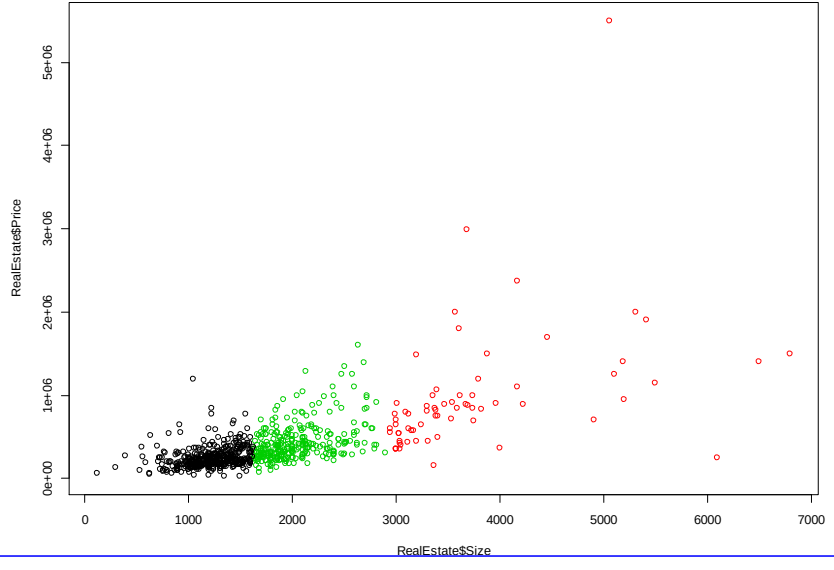
- est-il possible de prédire le prix véritable d'une maison à partir de sa superficie ?
  → utilisation de modèle de régression
  (régression linéaire ou non linéaire)

Introduction

- Les différentes étapes de l'analyse de données

- **mener une analyse formelle complète**

- est-il possible de regrouper les données dans des ensembles afin d'extraire les caractéristiques des prix de vente des maisons ?
  → classification
  (*clustering*)

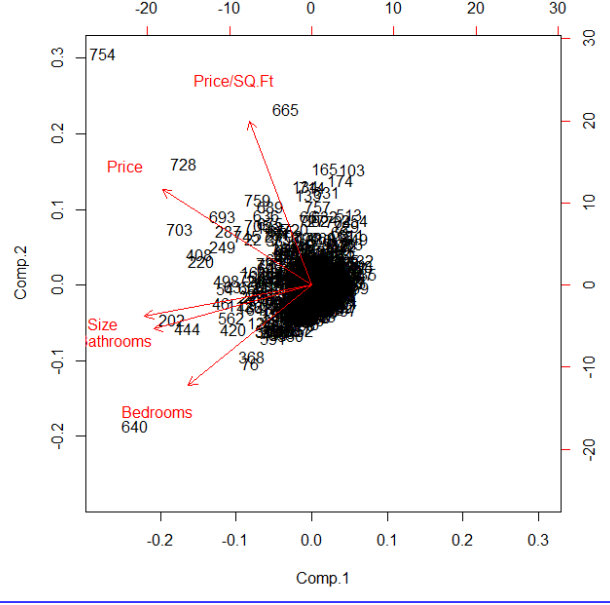


Introduction

- Les différentes étapes de l'analyse de données

- **mener une analyse formelle complète**

- est-il possible de représenter les données en *p* dimensions ?
  → analyse en composantes principales (ACP)



Introduction

• Les différentes étapes de l'analyse de données

- l'analyse de données est à l'intersection de différentes disciplines :

➢ les statistiques

➢ l'algèbre linéaire

➢ l'optimisation

Références

Gilbert Saporta
« Probabilités, analyse de données et statistiques »
Paris : Éditions TECHNIP, 2006 (2nde édition)

Première partie: Outils probabilistes
- Ch 2 : Variables aléatoires

Deuxième partie: Statistique exploratoire
- Ch 5 : Description unidimensionnelle de données numériques
- Ch 6 : Description bidimensionnelle et mesures de liaison entre variables
- Ch 7 : L'analyse en composantes principales
- Ch 11 : Méthodes de classification

Troisième partie: Statistique inférentielle

Quatrième partie: Modèles prédictifs
- Ch 16 : La régression simple

Cinquième partie : Recueil des données